

UNIDAD 3: Estadística Descriptiva de Datos Cuantitativos

Bioestadística (LCB) 2026

Introducción

Consideremos el siguiente *ejemplo*:

Los siguientes datos corresponden a una muestra de 52 plantas de soja de un cultivo de la Prov. de La Pampa en 2015, donde se ha contado el número de vainas por planta.

1, 3, 3, 2, 2, 2, 0, 0, 4, 4, 3, 3, 5, 5, 5, 1, 7, 7, 5, 5, 4, 4, 4, 4, 6, 6,
6, 1, 1, 0, 1, 2, 3, 3, 4, 4, 2, 2, 2, 2, 3, 3, 4, 4, 4, 4, 3, 5, 5, 5, 6, 6

En este caso los datos se encuentran **sin agrupar**, los datos aparecen según se fueron registrando y no se encuentran contabilizados o clasificados.

Las personas tenemos dificultades para procesar o tener en cuenta mucha información de forma simultánea.

Así pues, **¿qué se puede hacer?**

Una solución alternativa es organizar los datos de tal forma que tengan una disposición que facilite la lectura.

En este sentido, la primera acción a realizar es **ordenar** los datos desde el que posee el valor más pequeño hasta el que cuenta con el valor mayor.

Ordenamos los datos:

0, 0, 0, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 3, 3, 4,
4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 5, 5, 5, 5, 5, 5, 5, 5, 6, 6, 6, 6, 6, 7, 7

Parece que ésta es más fácil de interpretar.

No ha desaparecido ninguna información, el único cambio está en su ordenación. No obstante, la solución es parcial, puesto que aún debe ser mejorada.

Una buena estrategia es mostrar una sola vez cada número de vainas y la cantidad de plantas que tienen ese número de vainas.

De esta manera obtenemos **datos agrupados**


Número de vainas	Cantidad de plantas
0	3
1	5
2	8
3	9
4	12
5	8
6	5
7	2

Hay 3 formas de trabajar con los datos:

- **Datos sin agrupar (DS/A):** los datos aparecen según se fueron registrando y no se encuentran contabilizados o clasificados, se trabaja con datos sin agrupar cuando tenemos muy pocos datos u observaciones.
- **Datos en agrupación simple (DAS):** Se utiliza la **agrupación simple** cuando se trabaja con una gran cantidad de datos provenientes de variables cualitativas o cuantitativas discretas poco dispersas.
- **Datos agrupados en intervalos de clase (DAIC):** Se utiliza la **agrupación en intervalos de clase** cuando se trabaja con variables cuantitativas continuas o variables cuantitativas discretas pero:
 - La cantidad de datos es muy grande.
 - Pocos datos, pero muy dispersos (muy diferentes entre sí).
 - Interesa una clasificación particular de los resultados.

Frecuencias (DAS)

Existen 2 tipos de frecuencias expresados en distintos términos:



A tener en cuenta:

- Un nivel de medición estadístico **nominal**, solo admite **frecuencias simples**.
- Para un nivel de medición estadístico **superior al nominal** (es decir, ordinal, de intervalo, o de razón), los datos se pueden resumir con **frecuencias simples y acumuladas** (en este caso hay que ordenar los datos de menor a mayor).

Tabla de Frecuencias

Nro de tabla
Título

Variable	Frecuencias Simples			Frecuencias Acumuladas		
	f_i	r_i	p_i	F_i	R_i	P_i
...						
...						
...						
...				n	1	100
Totales	n	1	100			

Notas
Fuente

Donde:

f_i : frecuencia absoluta simple. Es el número de veces que se repite un valor de la variable en n observaciones. Como la cantidad de observaciones es n , la suma de las frecuencias simples debe ser igual al tamaño muestral n .

$r_i = \frac{f_i}{n}$: frecuencia relativa simple. Es la proporción de veces que aparece esa modalidad o valor entre todos los datos de la muestra. La suma de las frecuencias relativas simples debe ser igual a 1.

$p_i = r_i \cdot 100$: frecuencia porcentual simple. Es común expresar a las frecuencias relativas simples como porcentajes para una mejor comprensión de lo que representa. La suma de las frecuencias porcentuales simples debe ser igual a 100.

$F_i = \sum_{j=1}^i f_j$: **frecuencia absoluta acumulada**. Es suma de las frecuencias absolutas simples anteriores hasta el valor actual.

$R_i = \sum_{j=1}^i r_j$: **frecuencia relativa acumulada**. Es suma de las frecuencias relativas simples anteriores hasta el valor actual.

Observar que: $R_i = \frac{F_i}{n}$

$P_i = \sum_{j=1}^i p_j$: **frecuencia porcentual acumulada**. Es suma de las frecuencias porcentuales simples anteriores hasta el valor actual.

Observar que: $P_i = R_i \cdot 100$

Ejemplo 1:

Los siguientes datos corresponden a una muestra de 52 plantas de soja de un cultivo de la Prov. de La Pampa en 2015, donde se ha contado el número de vainas por planta.

1, 3, 3, 2, 2, 2, 0, 0, 4, 4, 3, 3, 5, 5, 5, 1, 7, 7, 5, 5, 4, 4, 4, 4, 6, 6,
6, 1, 1, 0, 1, 2, 3, 3, 4, 4, 2, 2, 2, 2, 3, 3, 4, 4, 4, 4, 3, 5, 5, 5, 6, 6

Ordenamos los datos:

0, 0, 0, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 3, 3, 3, 4,
4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 5, 5, 5, 5, 5, 5, 5, 5, 6, 6, 6, 6, 6, 6, 7, 7

Tabla N 1

**Cantidad de vainas por planta de soja de un cultivo de la
Prov. de La Pampa en 2015**

Cantidad de vainas	Frecuencias Simples			Frecuencias Acumuladas		
x_i	f_i	r_i	p_i	F_i	R_i	P_i
0	3	0.0577	5.77	3	0.0577	5.77
1	5	0.0962	9.62	8	0.1539	15.39
2	8	0.1538	15.38	16	0.3077	30.77
3	9	0.1731	17.31	25	0.4808	48.08
4	12	0.2308	23.08	37	0.7116	71.16
5	8	0.1538	15.38	45	0.8654	86.54
6	5	0.0962	9.62	50	0.9616	96.16
7	2	0.0385	3.85	52	1	100
Totales	52	1	100			

¿Cómo se interpretan los valores de la tabla resaltados?

Representaciones gráficas

Estos cuadros de distribuciones generalmente van acompañados de gráficas, específicas para cada caso, y que permiten una rápida comprensión de los datos.

Los gráficos para datos en agrupación simple son los siguientes:

- Gráfico de bastones.
- Gráfico escalonado.

Gráfico de Bastones:

- Se utiliza para datos cuantitativos en **agrupación simple**.
- En el eje de las abscisas se representan los valores de la variable y en el eje de las ordenadas las **frecuencias simples**.
- Cada valor de la variable se representa con un bastón cuya longitud determina el valor de la frecuencia simple.

Gráfico N° 1
Cantidad de vainas por planta de soja de un cultivo
de la Prov. de La Pampa en 2015





Gráfico escalonado:

- Se utiliza para datos cuantitativos en **agrupación simple**.
- En el eje de las abscisas se representan los valores de la variable y en el eje de las ordenadas los valores de las **frecuencias acumuladas**.
- Esta representación gráfica se corresponde con el de una función constante entre cada dos valores consecutivos de la variable a representar, formando así escalones (cerrados a izquierda) cuya altura es el valor de la frecuencia acumulada correspondiente.

Gráfico N°2
Cantidad de vainas por planta de soja de un cultivo
de la Prov. de La Pampa en 2015



Al agrupar los valores en intervalos de clase:

- Los intervalos deben ser disjuntos: cada observación debe estar contenida en un, y sólo un intervalo de clase (mutuamente excluyentes), además cada dato debe pertenecer a un intervalo (exhaustivos).
- Se pierde información sobre las observaciones, pero la variable es más "manejable".
- No pueden existir intervalos con frecuencia cero.
- La agrupación en intervalo no debe modificar la forma de la distribución original de los datos.

¿Cuántos intervalos?

- Recomendación: no inferior a 5, no superior a 20.
- Puede definirse previamente de acuerdo al criterio de los investigadores, eligiendo entre 5 y 20 intervalos.
- Algunos consideran $\sqrt{n}$ como primera aproximación, otros usan la regla de Sturges: $1 + 3.3 \cdot \log(n)$.

Amplitud:

Dadas las observaciones ordenadas: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$:

Rango de la información: $R = x_{(n)} - x_{(1)}$.

I = cantidad de intervalos.

Amplitud de los intervalos: $A = R/I$ (redondeando, si es necesario, al entero inmediato superior).

El primer intervalo de clase debe contener el valor mínimo ($x_{(1)}$) y el último al valor máximo ($x_{(n)}$).

Se pueden utilizar intervalos de **igual amplitud** o de **distinta amplitud**.

Notaciones y definiciones:

Sean L_{I_i} y L_{S_i} los límites inferior y superior del intervalo i -ésimo, $i = 1, \dots, k$, k = número de intervalos.

- Los intervalos, que deben ser disjuntos, pueden ser del tipo:

$L_{I_i} \leq x_i < L_{S_i}$ (incluyen al límite inferior), o

$L_{I_i} < x_i \leq L_{S_i}$ (incluyen al límite superior)

- Se define la **Marca de clase** del intervalo i a:

$$x'_i = \frac{L_{I_i} + L_{S_i}}{2} \quad (\text{también se la denota con } M_{C_i}, \text{ o simplemente } x_i)$$

- x'_i es el punto medio del intervalo i y es el "representante" de dicho intervalo.
- a_i es la amplitud del i -ésimo intervalo.

Intervalos de clase abiertos

- ▶ Se dice que una serie de clases y frecuencias es abierta en su extremo inferior cuando se desconoce la frontera inferior de su primera clase.
- ▶ Se dice que una serie de clases y frecuencias es abierta en su extremo superior cuando se desconoce la frontera superior de su última clase.

Ejemplos:

$L_I \leq x_i < L_S$
menos de 10
[10,12)
[12,16)
[16,18)
[18,20)

$L_I < x_i \leq L_S$
(10,12]
(12,16]
(16,18]
(18,20]
más de 20

- ▶ El caso de que una serie de clases y frecuencias es abierta en sus dos extremos se deduce fácilmente.

Densidad de frecuencia:

Se la utiliza principalmente cuando trabajamos con intervalos de distinta amplitud.

Se la denota generalmente por h_i y se la calcula por $h_i = \frac{f_i}{b_i}$,

donde $b_i = \frac{a_i}{a_{i\min}}$ (base del intervalo)

Cuando los intervalos son de igual amplitud, entonces todas las amplitudes son iguales y por lo tanto $b_i = 1$, entonces $h_i = f_i$

Cuerpo de la tabla de frecuencias :

Variable	Marca de clase	Frecuencias Simples			Frecuencias Acumuladas					
$L_I \leq x_i < L_S$	x'_i	f_i	r_i	p_i	F_i	R_i	P_i	a_i	b_i	h_i
...										
...										
...										
...					n	1	100			
	Totales	n	1	100						

(en este caso los intervalos están cerrados a izquierda, podrían ser cerrados a derecha)

Ejemplo 2:

Los siguientes datos corresponden a los pesos (kg) de una muestra de 65 empleados de una fábrica de la ciudad de Corrientes en 2010.

50,0 - 77,2 - 78,4 - 52,3 - 115,0 - 88,1 - 90,4 - 92,4 - 92,0 - 87,1 -
93,6 - 105,3 - 105,5 - 68,0 - 68,7 - 68,5 - 81,0 - 81,2 - 81,4 - 81,4
- 55,1 - 107,2 - 98,8 - 92,3 - 75,0 - 75,0 - 75,9 - 58,0 - 58,8 - 59,1
- 59,4 - 59,3 - 80,1 - 80,8 - 80,0 - 99,3 - 96,5 - 78,2 - 78,4 - 78,0 -
79,1 - 79,7 - 61,5 - 61,2 - 62,3 - 81,1 - 67,0 - 67,2 - 67,0 - 68,9 -
70,1 - 77,4 - 77,5 - 85,3 - 84,8 - 85,5 - 85,0 - 114,0 - 70,1 - 70,0 -
70,5 - 91,0 - 92,9 - 100,3 - 101,0

Ordenamos los datos:

50,0 - 52,3 - 55,1 - 58,0 - 58,8 - 59,1 - 59,3 - 59,4 - 61,2 - 61,5 -
62,3 - 67,0 - 67,0 - 67,2 - 68,0 - 68,5 - 68,7 - 68,9 - 70,0 - 70,1 -
70,1 - 70,5 - 75,0 - 75,0 - 75,9 - 77,2 - 77,4 - 77,5 - 78,0 - 78,2 -
78,4 - 78,4 - 79,1 - 79,7 - 80,0 - 80,1 - 80,8 - 81,0 - 81,1 - 81,2 -
81,4 - 81,4 - 84,8 - 85,0 - 85,3 - 85,5 - 87,1 - 88,1 - - 90,4 - 91,0 -
92,0 - 92,3 - 92,4 - 92,9 - 93,6 - 96,5 - 98,8 - 99,3 - 100,3 - 101,0
- 105,3 - 105,5 - 107,2 - 114,0 - 115,0

► Cantidad de intervalos (regla de Sturges):

$$1 + 3,3 \cdot \log(n) = 1 + 3,3 \cdot \log(65) = 6,98 \quad (7 \text{ intervalos})$$

► Amplitud: $\frac{|115-50|}{7} = 9,28$

Podríamos construir 7 intervalos de amplitud 10.

Ejemplo 2:

Construimos la tabla de frecuencias:

Tabla N 2

Pesos de una muestra de 65 empleados de una fábrica de la ciudad de Corrientes en 2010

Pesos	Marca de clase	Frecuencias Simples			Frecuencias Acumuladas		
$L_I \leq x_i < L_S$	x'_i	f_i	r_i	p_i	F_i	R_i	P_i
[50,60)	55	8	0.1231	12.31	8	0.1231	12.31
[60,70)	65	10	0.1538	15.38	18	0.2769	27.69
[70,80)	75	16	0.2462	24.62	34	0.5231	52.31
[80,90)	85	14	0.2154	21.54	48	0.7385	73.85
[90,100)	95	10	0.1538	15.38	58	0.8923	89.23
[100,110)	105	5	0.077	7.7	63	0.9693	96.93
[110,120)	115	2	0.0307	3.07	65	1	100
	Totales	65	1	100			

Interprete los valores de una fila de esta.

Representaciones gráficas

Los gráficos para datos agrupados en intervalos de clase son los siguientes:

- Histograma
- Polígono de frecuencias
- Ojiva o Polígono de frecuencias acumuladas

Histograma:


- Se utiliza para **datos agrupados en intervalos de clase**.
- En el eje de las abscisas se representan los intervalos de clase.
- En el eje de las ordenadas se representan las **frecuencias simples**.
- Sobre cada intervalo se levantan rectángulos cuya base es la longitud del intervalo de clase y su altura es tal que el área del rectángulo sea proporcional a la frecuencia del intervalo.
- Si los intervalos son de la misma amplitud, el ancho del rectángulo es fijo y la altura del mismo corresponde a la frecuencia que se este considerando.

Polígono de frecuencias:

- Se utiliza para **datos agrupados en intervalos de clase**.
- En el eje de las abscisas se representan las marcas de clase.
- En el eje de las ordenadas se representan las **frecuencias simples**.
- Se unen esos puntos con segmentos de recta.

Observación: se puede confeccionar el histograma y el polígono de frecuencias por separado pero generalmente se grafican los dos juntos.


Gráfico N° 3
Pesos de una muestra de 65 empleados de una fábrica
de la ciudad de Corrientes en 2010



Ojiva o Polígono de frecuencias acumuladas:

- Se utiliza para **datos agrupados en intervalos de clase**.
- En el eje de las abscisas se representan los límites de los intervalos de clase.
- En el eje de las ordenadas se representan **frecuencias acumuladas** sobre el límite superior del intervalo.
- Al límite inferior del primer intervalo se le asigna el valor 0.
- Se unen esos puntos con segmentos de recta.


Gráfico N° 4
Pesos de una muestra de 65 empleados de una fábrica
de la ciudad de Corrientes en 2010



Medidas Descriptivas

Objetivo: caracterizar una distribución por medio de un número reducido de medidas numéricas.

Estas medidas están rigurosamente definidas y brindan en forma resumida información del conjunto total de datos y una idea del comportamiento global de la población o muestra en estudio.



Medidas Descriptivas

- **Medidas de tendencia central:** son medidas que *tienden* a estar en el centro de la distribución de datos. Caracterizan el centro de la distribución, esto es: alrededor de qué valor se agrupan los datos.
- **Medidas de posición:** son medidas cuyos valores dividen en fracciones al conjunto ordenado de unidades elementales según el valor de la variable.
- **Medidas de dispersión o variabilidad:** son las que describen cuán dispersos están los datos. La dispersión se puede medir respecto a alguna medida de tendencia central (MTC) o no.

- **Medidas de forma:** como su nombre lo indica describen la forma de la distribución de datos. Las medidas de forma permiten comprobar si una distribución de frecuencia tiene características especiales como simetría, asimetría y nivel de apuntamiento que la clasifiquen en un tipo particular de distribución. Las medidas de forma son necesarias para determinar el comportamiento de los datos y así, poder adaptar herramientas para el análisis probabilístico. Algunas medidas de forma son los coeficientes de asimetría de Fisher y Pearson.
 - **Asimetría:** con estas medidas se trata de establecer si una distribución de datos es asimétrica o no, y en segundo caso, el grado de asimetría.
 - **Curtois:** mide la agudeza (elevación o achatamiento) de una distribución de datos comparada con la distribución normal (que será estudiada con más detalles en el transcurso del desarrollo de la asignatura).

Media aritmética

Media aritmética: es la medida de resumen más conocida como “promedio”. Es un valor que representa a cada uno de los valores de la variable en estudio (para variables cuantitativas).

Para **datos sin agrupar**, la media aritmética se calcula como suma de las observaciones dividida entre el número de observaciones, se la denota con $\bar{X}$ y su fórmula es:

$$\bar{X} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

siendo n el tamaño del conjunto de observaciones.

Ejemplo 1:

Ejemplo 1: Los siguientes datos corresponden a las edades de una muestra de 10 empleados de cierta cafetería muy popular de la ciudad de Bs. As. en 2017.

24, 19, 20, 22, 20, 22, 22, 21, 21, 19

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} = \frac{24 + 19 + 20 + 22 + 20 + 22 + 22 + 21 + 21 + 19}{10} = 21 \text{ años}$$

Interpretación: los empleados de cierta cafetería muy popular de la ciudad de Bs. As. en 2017, tienen en promedio 21 años

Cálculo de la media aritmética para DAS:

Si en una muestra de tamaño n hay k valores distintos de la variable $x_1, x_2, x_3, \dots, x_k$, con frecuencias absolutas simples $f_1, f_2, f_3, \dots, f_k$, la media aritmética es:

$$\bar{X} = \frac{\sum_{i=1}^k x_i f_i}{n}$$

Ejemplo: nro. de vainas por planta de soja.

$$\bar{X} = \frac{\sum_{i=1}^k x_i f_i}{n} = \frac{0.3 + 1.5 + 2.8 + 3.9 + 4.12 + 5.8 + 6.5 + 7.2}{52} = 3,46 \text{ vainas}$$

Interpretación: en promedio, cada planta de soja tiene 3,46 vainas.

Cálculo de la media aritmética para DAIC:

Si la muestra es de tamaño n y se ha resumido en k intervalos de clase, la media aritmética es:

$$\bar{X} = \frac{\sum_{i=1}^k x'_i f_i}{n}$$

Ejemplo: peso de empleados.

$$\bar{X} = \frac{\sum_{i=1}^k x'_i f_i}{n} = \frac{55.8 + 65.10 + 75.16 + 85.14 + 95.10 + 105.5 + 115.2}{65} = 79,77 \text{ kg.}$$

Interpretación: en promedio el peso de los empleados de la fábrica es de 79.77 kg.

RESUMEN:

Tipo de datos	Fórmula	Interpretación	Comentario
DSA	$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$	x_i : dato n : cantidad	Promedio simple.
DAS	$\bar{X} = \frac{\sum_{i=1}^k x_i f_i}{n}$	x_i : valor f_i : frecuencia $n = \sum f_i$	Media ponderada.
DAIC	$\bar{X} = \frac{\sum_{i=1}^k x'_i f_i}{n}$	x'_i : marca de clase f_i : frecuencia $n = \sum f_i$	Aproximación.

Propiedades

- La media aritmética es un valor representativo del conjunto de valores observados, ya que puede reemplazar a cada uno de ellos sin que altere el total.

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} \Rightarrow \sum_{i=1}^n x_i = n\bar{X}$$

- La suma de los desvíos de cada valor observado y la media aritmética es igual a cero.

Desvío: $d_i = x_i - \bar{X}$

$$\sum_{i=1}^n d_i = \sum_{i=1}^n (x_i - \bar{X}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{X} = n\bar{X} - n\bar{X} = 0$$

- Si a un conjunto de datos le sumamos o restamos una constante k , la media del nuevo conjunto va a quedar afectada por esa constante y va a ser igual a la media del conjunto anterior más o menos esa constante.

Sean: x_i con $i = 1, \dots, n$ un conjunto de datos y $\bar{X}$ su media

si $z_i = x_i + k$, entonces $\bar{Z} = \bar{X} + k$

$$\begin{aligned}\bar{Z} &= \frac{\sum_{i=1}^n z_i}{n} = \frac{\sum_{i=1}^n (x_i + k)}{n} = \frac{\sum_{i=1}^n x_i + \sum_{i=1}^n k}{n} = \\ &= \frac{\sum_{i=1}^n x_i}{n} + \frac{\sum_{i=1}^n k}{n} = \frac{\sum_{i=1}^n x_i}{n} + \frac{nk}{n} = \bar{X} + k\end{aligned}$$

Análogamente para la resta.

- Si a un conjunto de datos los multiplicamos o dividimos una constante k , la media del nuevo conjunto va a quedar afectada por esa constante y va a ser igual a la media del conjunto anterior multiplicada o dividida esa constante.

Sean: x_i con $i = 1, \dots, n$ un conjunto de datos y $\bar{X}$ su media
si $z_i = kx_i$, entonces $\bar{Z} = k\bar{X}$

$$\bar{Z} = \frac{\sum_{i=1}^n z_i}{n} = \frac{\sum_{i=1}^n kx_i}{n} = \frac{k \sum_{i=1}^n x_i}{n} = k \frac{\sum_{i=1}^n x_i}{n} = k\bar{X}$$

Análogamente para la división.

- La media aritmética es el punto de equilibrio o centro de gravedad del conjunto de datos observados. Es decir los valores de las observaciones en un lado de la media igualan a los valores de las observaciones en el otro lado de ella. Si imaginamos al conjunto de datos como pesas apoyadas sobre una balanza la media aritmética es el punto donde hay que apoyar para que el conjunto de datos esté en equilibrio.

Ventajas y desventajas

Ventajas:

- En su cálculo intervienen todos los datos.
- Tiene fácil manejo algebraico y posee propiedades que la hacen aptas para la construcción de otras medidas descriptivas.
- Se expresa en las mismas unidades que la variable en estudio.
- Es un valor único.
- Se trata de un concepto familiar para la mayoría de las personas.

Desventajas:

- Solo puede utilizarse para variables cuantitativas.
- Es una medida que está afectada por los valores extremos, por lo que en caso de que existan **valores atípicos o outliers** (particularmente altos o bajos) en el conjunto, la media **deja de ser representativa**, pues como en la media intervienen todos los datos si hay valores atípicos harán que la media se desplace en esa dirección.

Ejemplo: consideremos 2 conjuntos de datos

$$6 - 5 - 9 - 7 - 8 - 10 \rightarrow \bar{X} = 7,5$$

$$6 - 5 - 9 - 7 - 8 - \underbrace{100}_{\text{valor atípico}} \rightarrow \bar{X} = 22,5$$

Se puede observar cómo la media del segundo conjunto se ve afectada por el valor atípico.

Mediana

Mediana: es aquel valor de la variable en estudio que divide al conjunto de datos ordenados en dos partes iguales, de tal forma que el 50 % de las unidades elementales tienen un valor menor o igual a dicho valor y el otro 50 % un valor superior o a lo sumo igual.

Al requerir datos ordenados, esta medida se aplica a variables cuya clasificación tengan *al menos un Nivel de Medición Estadístico: Ordinal o Jerárquico*, es decir variables cualitativas con escala ordinal, o cuantitativas con escala de razón o de intervalo.

Cálculo de la mediana: DSA

- Si n es impar la mediana es igual al valor que ocupa la posición $\frac{n+1}{2}$ en la ordenación.

$$Me = x_{\left(\frac{n+1}{2}\right)}$$

Ejemplo: 2-2-4-6-7, $Me = x_{\left(\frac{5+1}{2}\right)} = x_{(3)} = 4$

- Si n es par la mediana es igual al promedio de los valores que ocupan las posiciones centrales en la ordenación.

$$Me = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}$$

Ejemplo: 2-2-5-6-6-7,

$$Me = \frac{x_{\left(\frac{6}{2}\right)} + x_{\left(\frac{6}{2}+1\right)}}{2} = \frac{x_{(3)} + x_{(4)}}{2} = \frac{5 + 6}{2} = 5,5$$

Ejemplo 1:

Continuación del Ejemplo 1:

Para hallar la mediana es necesario ordenar primero el conjunto de datos:

19, 19, 20, 20, 21, 21, 22, 22, 22, 24

Como $n=10$ es par:

$$Me = \frac{x_{(\frac{10}{2})} + x_{(\frac{10}{2}+1)}}{2} = \frac{x_{(5)} + x_{(6)}}{2} = \frac{21 + 21}{2} = 21 \text{ años}$$

Interpretación: el 50% de los empleados tiene 21 años o menos, por lo tanto el 50% restante tiene 21 años o más.

Cálculo de la mediana: DAS

Para calcular la mediana, utilizamos la columna de frecuencias absolutas acumuladas. En ella buscamos el primer valor de x_j que supere $n/2$.

Otra opción consiste en buscar en la columna de frecuencias porcentuales acumuladas. En ella buscaremos el primer valor de x_j que acumule el 50 %.

Siguiendo con el ejemplo del número de vainas en plantas de soja:

$$\frac{n}{2} = \frac{52}{2} = 26.$$

Buscamos ahora en la columna F_i el primer valor de x_j que acumule 26. Este valor es 4, por lo que

$$Me = 4$$

Interpretación: el 50% de las plantas de soja tiene 4 vainas o menos, por lo tanto el otro 50% tiene 4 vainas o más.

Cálculo de la mediana:DAIC

- 1 Calcular $n/2$.
- 2 Buscar en la tabla de frecuencias absolutas acumuladas (F_i) el intervalo de clase que contenga a la frecuencia $n/2$ (intervalo que contiene la mediana) y sea más próxima.

3 Calcular:

$$Me = L_I + \frac{\frac{n}{2} - F_{i-1}}{f_i} \cdot a_i$$

Donde:

L_I : límite inferior del intervalo que contiene a la mediana.

F_{i-1} : frec. abs. acumulada del intervalo anterior al que contiene a la mediana.

f_i : frecuencia absoluta simple del intervalo que contiene a la mediana.

a_i : amplitud del intervalo que contiene a la mediana.

n : cantidad de individuos en estudio.

Siguiendo con el ejemplo del peso de los empleados:

❶ $n/2 = 65/2 = 32,5$


❷ Intervalo que contiene a la mediana: **[70,80)**

❸
$$Me = L_I + \frac{\frac{n}{2} - F_{i-1}}{f_i} \cdot a_i = 70 + \frac{32,5 - 18}{16} 10 = 79,06 \text{ kg}$$

Interpretación: el 50% de los empleados de la fábrica tiene un peso de 79.06 kg o menos, por lo tanto el otro 50% de los empleados tiene un peso de 79,06 kg o más.

Se puede obtener el valor aproximado de la mediana en forma gráfica utilizando la ojiva.

Gráfico N° 4
Pesos de una muestra de 65 empleados de una fábrica
de la ciudad de Corrientes en 2010



Ventajas y desventajas

Ventajas:

- El cálculo es rápido y de manera sencilla.
- La mediana no se ve afectada por valores atípicos, decimos entonces que la mediana es una medida robusta.

Desventajas:

- En su cálculo no intervienen todos los datos, por lo tanto no utiliza toda la información disponible.
- Para determinarla si o si es necesario ordenar los datos previamente.

Moda o Modo: DSA

Moda: es aquel valor de la variable en estudio que se presenta con mayor frecuencia.

Puede haber más de una moda (distribución bimodal, trimodal, multimodal), o no existir.

Siguiendo con el ejemplo 1:

Para hallar la moda observamos cual es el valor de la variable en estudio que se presenta con mayor frecuencia:

19, 19, 20, 20, 21, 21, 22, 22, 22, 24

Como 22 años se repite más veces:

$Mo=22$ años

Interpretación: la edad de los empleados que se presentó con mayor frecuencia es de 22 años.

Cálculo de la moda: DAS

Se mira en la tabla el valor de la variable que tienen mayor frecuencia simple.

En el ejemplo del número de vainas por planta de soja:

$Mo = 4$ vainas.

Interpretación: la cantidad de vainas por plantas de soja que se presentó con mayor frecuencia es 4.

Cálculo de la moda: DAIC

- 1 Determinar la clase modal, que es la de mayor frecuencia simple.

- 2 Calcular:
$$Mo = L_I + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot a_i$$

Donde:

$$\Delta_1 = f_{modal} - f_{premodal}$$

$$\Delta_2 = f_{modal} - f_{posmodal}$$

Ejemplo de peso de empleados:

① Clase modal: **[70,80)**

②
$$Mo = L_I + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot a_i = 70 + \frac{6}{6 + 2} 10 = 77,5 \text{ kg}$$

CA:


$$\Delta_1 = f_{\text{modal}} - f_{\text{premodal}} = 16 - 10 = 6$$

$$\Delta_2 = f_{\text{modal}} - f_{\text{posmodal}} = 16 - 14 = 2$$

Interpretación: el peso de 77,5 kg es el que se presentó con mayor frecuencia entre los empleados de la fábrica.

Se puede obtener el valor aproximado de la moda en forma gráfica.

Gráfico N° 3
Pesos de una muestra de 65 empleados de una fábrica
de la ciudad de Corrientes en 2010



Ventajas y desventajas

Ventajas:

- Puede usarse tanto para datos cualitativos como para datos cuantitativos.
- En general, es fácil de interpretar.
- No se ve influenciada por valores atípicos.

Desventajas:

- En su cálculo no intervienen todos los datos, por lo tanto no utiliza toda la información disponible.
- No siempre existe, como en el caso donde todos los datos tienen la misma frecuencia.
- Cuando tiene más de una moda puede ser difícil de interpretar, además deja de ser una medida representativa.

Medidas de posición (Cuantiles)

Son valores de la variable en estudio que dividen al conjunto ordenado de datos observados en fracciones de tal manera que deja un porcentaje $k\%$ de unidades elementales por debajo de ese valor y un $(100 - k)\%$ de unidades elementales por encima del mismo.

- **Cuartiles:** Q_i , $i = 1, 2, 3$: dividen el conjunto de observaciones en 4 partes iguales.
- **Quintiles:** K_i , $i = 1, 2, 3, 4$: dividen el conjunto de observaciones en 5 partes iguales.
- **Deciles:** D_i , $i = 1, 2, \dots, 9$: dividen el conjunto de observaciones en 10 partes iguales.
- **Percentiles:** P_i , $i = 1, 2, \dots, 99$: dividen el conjunto de observaciones en 100 partes iguales.

Cálculo de cuantiles: DSA

Pasos:

- 1 Se ordenan los datos.
- 2 Se define k : porcentaje de valores que quedan por debajo del valor buscado.
- 3 Se calcula $i = \frac{nk}{100}$ como primera aproximación de la posición buscada.
- 4
 - Si i es un número entero, entonces $\text{Cuantil} = x_{(i)}$
 - Si i no es un número entero, se toman el valor de la posición entera más próxima por defecto y más próxima por exceso y se los promedia.

Ejemplo 1:

Ejemplo 1:

Para hallar por ejemplo el cuartil 1 (o primer cuartil) Q_1 :

19, 19, 20, 20, 21, 21, 22, 22, 22, 24

$$k = 25$$

$$i = \frac{nk}{100} = \frac{10 \cdot 25}{100} = 2,5;$$

i no es un número entero, se toman $x_{(2)}$ y $x_{(3)}$.

$$Q_1 = \frac{x_{(2)} + x_{(3)}}{2} = \frac{19 + 20}{2} = 19,5 \text{ años}$$

Interpretación: el 25% de los empleados tiene 19,5 años o menos, por lo tanto el 75% restante tiene 19,5 años o más.

Cálculo de cuantiles: DAS

Pasos:


- 1 Se define k : porcentaje de valores que quedan por debajo del valor buscado.
- 2 Se calcula la posición teórica del cuantil: $i = \frac{nk}{100}$. donde n es el total de datos.
- 3 Se busca el menor valor x_j cuya frecuencia acumulada F_j verifique:

$$F_j \geq i$$

- 4 Entonces: Cuantil = x_j

Nota: Equivalentemente, pueden buscar en la columna de las frecuencias porcentuales acumuladas el primer valor de x_j que supere $k\%$.

Consideremos el *ejemplo de las vainas* y calculemos el primer cuartil Q_1 :




En este caso: $k = 25$, luego: $i = \frac{nk}{100} = \frac{52.25}{100} = 13$

Buscamos en la columna de frecuencias acumuladas el primer valor x_j que acumule 13. En este caso, ese valor es 2, entonces:

$$Q_1 = 2$$

Interpretación: el 25% de las plantas de soja tiene 2 vainas o menos, por lo tanto el 75% restante tiene 2 vainas o más.

Calculemos ahora el *segundo cuartil* Q_2 :



En este caso: $k = 50$, luego $i = \frac{nk}{100} = \frac{52.50}{100} = 26$.

Buscamos en la columna de las frecuencias acumuladas el primer valor de x que acumule 26 observaciones, que es: 4.

$$Q_2 = 4$$

Interpretación: el 50% de las plantas de soja tiene 4 vainas o menos, por lo tanto el otro 50% tiene 4 vainas o más.

Cálculo de cuantiles:DAIC

Pasos:

- 1 Se define k : porcentaje de valores que quedan por debajo del valor buscado.
- 2 Se busca en la tabla de frecuencias aquel intervalo donde se haya acumulado el valor k (generalmente se busca en la columna de frecuencias porcentuales acumuladas).

- 3 Se calcula:
$$\text{Cuantil} = L_i + \frac{\frac{nk}{100} - F_{i-1}}{f_i} \cdot a_i$$

Ejemplo del peso de empleados: calculemos el primer cuartil Q_1 :

- 1 Se identifica el intervalo que contenga el cuartil buscado con la fórmula $\frac{nk}{100}$, donde k : porcentaje de valores que quedan por debajo del valor buscado.

En este caso: $k = 25$, luego: $\frac{nk}{100} = \frac{65 \cdot 25}{100} = 16,25$, luego el intervalo a considerar es: **[60,70)**

- 2 Calculamos:

$$Q_1 = L_I + \frac{\frac{n}{4} - F_{i-1}}{f_i} \cdot a_i = 60 + \frac{16,25 - 8}{10} 10 = 68,25 \text{ kg}$$

Interpretación: el 25% de los empleados de la fábrica tiene un peso menor o igual 68.25 kg, por lo tanto el 75% de los empleados tiene un peso mayor o igual a 68.25 kg.

Se tendrá que:

- $Q_1 = L_I + \frac{\frac{n}{4} - F_{i-1}}{f_i} \cdot a_i$
- $Q_2 = L_I + \frac{\frac{n}{2} - F_{i-1}}{f_i} \cdot a_i$
- $Q_3 = L_I + \frac{\frac{3}{4}n - F_{i-1}}{f_i} \cdot a_i$

Medidas de dispersión, variación o variabilidad

Son valores numéricos que nos dan información sobre cuán esparcidos o concentrados se encuentran los datos.

- Medidas de dispersión absolutas (dependen solamente de los datos):
 - Rango.
 - Rango intercuartílico.
 - Varianza.
 - Desviación estándar o típica.
- Medida de dispersión relativa:
 - Coeficiente de variación.

Rango

El rango, amplitud o recorrido es la diferencia entre el máximo y mínimo valor de la variable.

Fórmula: $R = x_{(n)} - x_{(1)}$

Ejemplo: edad de empleados $R = 24 - 19 = 5$ años

Interpretación: existe una amplitud máxima de 5 años entre las edades de los empleados.

Nota: En el caso de los DAS, el cálculo del Rango es exactamente igual. Cuando los datos se encuentran en DAIC, el rango se calcula como la diferencia entre el límite superior del último intervalo y el límite inferior del primero de ellos (siempre y cuando estos límites existan).

Rango

Ventajas:

- Fácil de calcular.
- Es útil cuando se quiere conocer la extensión de las variaciones extremas (valor máximo de dispersión).

Desventajas:

- En su cálculo solo intervienen 2 datos, por lo tanto no utiliza toda la información disponible.
- Está influenciada por los valores extremos, por lo que resulta ser una medida inestable que queda afectada por el tamaño de la muestra. (Si se agrega o se quita un dato, puede variar su resultado en forma significativa).

Rango intercuartílico

El rango intercuartílico o desviación intercuartil indica la amplitud del 50 % central de la distribución de datos ordenados.

Fórmula: $RI = Q_3 - Q_1$

Ejemplo: edad de empleados: $R = 22 - 20 = 2$ años

Interpretación: la amplitud del intervalo donde se encuentra el 50% central de las edades de los empleados es de 2 años.

Nota: En caso de trabajar con DAS o DAIC, el cálculo e interpretación es el mismo.

Rango intercuartílico

Ventaja:

- Es un poco mejor que el Rango dado que no está influenciado por los valores extremos. Además nos indica la amplitud del 50 % central de la distribución, donde se concentran los datos y se ubican las MTC.

Desventaja:

- En su cálculo no intervienen todos datos, por lo tanto no utiliza toda la información disponible.

Varianza (DSA)

Es el promedio de los cuadrados de las desviaciones de los valores respecto a la media aritmética.

$$\text{Fórmula (DSA): } S^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n}$$

Si bien la fórmula anterior es correcta, en la práctica si trabajamos con una muestra se utiliza $n - 1$ en lugar de n , ya que de esta forma se obtienen propiedades de interés. Es decir, que utilizamos:

$$\hat{S}^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1}$$

(A $\hat{S}^2$ suele denominarse varianza insesgada o cuasi-varianza)

Ejemplo (DSA):

$$\begin{aligned}\hat{S}^2 &= \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1} = \\ &= \frac{(19 - 21)^2 + (19 - 21)^2 + (20 - 21)^2 + (20 - 21)^2 + (21 - 21)^2}{10 - 1} \\ &+ \frac{(21 - 21)^2 + (22 - 21)^2 + (22 - 21)^2 + (22 - 21)^2 + (24 - 21)^2}{10 - 1} = \\ &2,44 \text{ años}^2\end{aligned}$$

Interpretación: la variabilidad promedio de las edades de los empleados respecto a su media al cuadrado es de 2,44 años².

Varianza (DAS)

$$\hat{S}^2 = \frac{\sum_{i=1}^k (x_i - \bar{X})^2 \cdot f_i}{n - 1}$$

En el *ejemplo del número de vainas*:

$$\frac{(0 - 3,46)^2 3 + (1 - 3,46)^2 5 + (2 - 3,46)^2 8 + (3 - 3,46)^2 9 + \dots + (7 - 3,46)^2 2}{52 - 1} =$$

$$= 3,233 \text{ vainas}^2$$

Interpretación: la variabilidad promedio de la cantidad de vainas por plantas de soja respecto a su media al cuadrado es de 3,233 vainas².

Varianza: DAIC

$$\hat{S}^2 = \frac{\sum_{i=1}^k (x'_i - \bar{X})^2 \cdot f_i}{n - 1}$$

Ejemplo: peso de empleados

$$\hat{S}^2 = \frac{\sum_{i=1}^k (x'_i - \bar{X})^2 \cdot f_i}{n - 1} = 247,21 \text{ kg}^2$$

Interpretación: la variabilidad promedio del peso de los empleados de la fábrica respecto a su media al cuadrado es de 247.21 kg².

Ventaja:

- En su cálculo intervienen todos los datos observados.

Desventaja:

- Se pierde la unidad de medida original (queda afectada al cuadrado).
- Es sensible a la presencia de datos atípicos.

Desviación típica o estándar

Para solucionar el problema de que la unidad de medida de la Varianza que queda al cuadrado, calculamos la raíz cuadrada, así surge el concepto de la Desviación Típica: $S = \sqrt{S^2}$

Análogamente al caso anterior, en la práctica usamos: $\hat{S} = \sqrt{\hat{S}^2}$

Ejemplo de edades de empleados:

$$\hat{S} = \sqrt{\hat{S}^2} = \sqrt{2,44} = 1,56 \text{ años}$$

Interpretación: la variabilidad promedio de las edades de los empleados respecto a su media es de 1,56 años.

Tarea: Calculen e interpreten la desviación típica en los ejemplos de número de vainas por planta de soja y peso de empleados.

Desviación típica o estándar

Ventajas:

- En su cálculo intervienen todos los datos observados.
- Está expresada en las mismas unidades que la variable en estudio.

Desventajas:

- Es sensible a la presencia de datos atípicos.

Coeficiente de variación: Problema inicial

Situación:

- Cultivo A: media = 50 cm, desvío = 5 cm
- Cultivo B: media = 30 cm, desvío = 6 cm

Pregunta

¿Cuál cultivo es más variable?

Discusión

¿Alcanza con comparar los desvíos estándar?

Discusión

- El desvío estándar mide variabilidad **absoluta**.
- Pero las medias son distintas.
- Entonces, la comparación no es directa.

Pregunta guía

¿Cómo podríamos comparar la variabilidad teniendo en cuenta la media?

Definición (idea descriptiva)

Idea clave

El **coeficiente de variación** mide cuán grande es la variabilidad de los datos en relación con el valor medio.

- Es una medida de dispersión **relativa**.
- Permite comparar conjuntos con distintas escalas.

Interpretación intuitiva

- CV bajo $\rightarrow$ datos relativamente homogéneos.
- CV alto $\rightarrow$ datos relativamente heterogéneos.

Ejemplo conceptual

Un desvío de 5 unidades:

- es pequeño si la media es 100.
- es grande si la media es 10.

Definición formal

$$CV = \frac{\hat{S}}{|\overline{X}|}$$

- $\hat{S}$: desvío estándar.
- $\overline{X}$: media aritmética.

Para facilitar la interpretación, se lo suele utilizar en términos de porcentaje.

$$CV = \frac{\hat{S}}{|\overline{X}|} \cdot 100 \%$$

Volvemos al problema inicial

- Cultivo A: $\bar{X}_A = 50$, $\hat{S}_A = 5$.
- Cultivo B: $\bar{X}_B = 30$, $\hat{S}_B = 6$.

Actividad

Calcular el coeficiente de variación en cada caso.

$$CV_A = 10\%, \quad CV_B = 20\%$$

Conclusión

El cultivo B es más variable en términos relativos. O bien, el cultivo A es más homogéneo en términos relativos.

Actividad 2:

- Condición 1: $\bar{X}_1 = 100$, $\hat{S}_1 = 10$.
- Condición 2: $\bar{X}_2 = 20$, $\hat{S}_2 = 8$.

Preguntas

- ¿Cuál tiene mayor variabilidad absoluta?
- ¿Y mayor variabilidad relativa?

$$CV_1 = 10\%, \quad CV_2 = 40\%$$

Interpretación

Para pensar

- ¿Qué implica un CV alto en un experimento?
 - ¿Qué implicancias tiene para la confiabilidad?
-
- CV bajo $\rightarrow$ mayor homogeneidad.
 - CV alto $\rightarrow$ mayor dispersión relativa.

Para terminar:

Resumen

- El CV mide variabilidad relativa.
- Permite comparar entre distintas escalas.
- Debe interpretarse junto con la media.

Pregunta final

¿En qué situaciones biológicas usarían el coeficiente de variación?

Medidas de forma: Coeficiente de asimetría

Grado de simetría de una distribución respecto a una medida de tendencia central (que generalmente es la media aritmética). Una distribución puede ser:

- **simétrica:** los valores equidistantes de una posición central tienen la misma frecuencia.
- **asimétrica positiva:** las frecuencias más altas corresponden a valores que se encuentran al lado izquierdo de esa posición central (cola a la derecha).
- **asimétrica negativa:** distribuciones con cola a la izquierda.

Una distribución es sesgada, si NO es simétrica.




Coeficientes de asimetría

Se define el **coeficiente de asimetría de Pearson** como:

$$A_p = \frac{3(\bar{X} - Me)}{\hat{S}}$$

Este coeficiente solo se puede utilizar en distribuciones uniformes, unimodales y moderadamente asimétricas.

- Si $A_p = 0$ la distribución es simétrica ($\bar{X} = Me = Mo$).
- Si $A_p > 0$ la distribución es asimétrica positiva ($\bar{X} > Me > Mo$).
- Si $A_p < 0$ la distribución es asimétrica negativa ($\bar{X} < Me < Mo$).



Coeficientes de asimetría: DSA

Otra forma de calcular la asimetría, es utilizar el llamado coeficiente de **FISHER** que representaremos como A_F y responderá a la siguiente expresión matemática:

$$A_F = \frac{\sum_{i=1}^n (x_i - \bar{X})^3}{n\hat{S}^3}$$

- Si $A_F = 0$ la distribución es simétrica.
- Si $A_F > 0$ la distribución es asimétrica positiva.
- Si $A_F < 0$ la distribución es asimétrica negativa.

Ejemplo

Si continuamos con el ejemplo de edades de trabajadores:

$$A_F = \frac{\sum_{i=1}^n (x_i - \bar{X})^3}{n\hat{S}^3} = 1,36$$

Interpretación: la distribución de las edades de los empleados es asimétrica positiva. Es decir, la mayor cantidad de observaciones es para edades menores a la media.

Curtosis

Se aplica a distribuciones unimodales simétricas o ligeramente asimétricas, ya que representa la elevación o achatamiento de una distribución comparada con la distribución normal, (*esta distribución se estudiará en unidades siguientes*).

La distribución normal adopta la forma de una campana perfectamente simétrica como:



Curtosis: DSA


Fórmula:

$$C_F = \frac{\sum_{i=1}^n (x_i - \bar{X})^4}{n\hat{S}^4} - 3$$

- Si $C_F = 0$ mismo grado de elevación que distribución normal (Mesocúrtica).
- Si $C_F > 0$ más apuntamiento que distribución normal (Leptocúrtica).
- Si $C_F < 0$ menor grado de elevación que distribución normal (Platicúrtica).



Leptocúrtica



Mesocúrtica



Platicúrtica

Diagrama de tallo y hojas

Forma rápida de obtener una representación visual de un conjunto de datos numéricos. Pasos:

- Se divide cada x_i en dos partes: Tallo (uno o más dígitos) y Hoja (dígito restante (en algunos casos pueden ser dos dígitos)).
- Una vez establecidos los tallos: listarlos en el margen izquierdo de la página.
- Se traza una línea vertical a la derecha de la columna del tallo y al lado de cada uno, listar en fila las hojas correspondientes a TODAS las observaciones ordenadas de menor a mayor.

Ejemplo

Los siguientes datos representan los latidos cardíacos por minuto de un grupo de 30 personas después de cierta actividad física:

82 – 95 – 92 – 62 – 85 – 92 – 82 – 95 – 70 – 85 – 84 – 95 – 91 – 82 – 94 – 76 – 88 – 91 – 87 – 80 – 68 – 58 – 76 – 85 – 110 – 60 – 75 – 88 – 64 – 74

Ordenamos: 58 – 60 – 62 – 64 – 68 – 70 – 74 – 75 – 76 – 76 – 80 – 82 – 82 – 82 – 84 – 85 – 85 – 85 – 87 – 88 – 88 – 91 – 91 – 92 – 92 – 94 – 95 – 95 – 95 – 110

Gráfico N 5

Latidos cardíacos de 30 personas después de cierta actividad física.

Tallo	Hojas										
5	8										
6	0	2	4	8							
7	0	4	5	6	6						
8	0	2	2	2	4	5	5	5	7	8	8
9	1	1	2	2	4	5	5	5			
11	0										

Diagrama de caja y bigotes o boxplot

Los diagramas de caja y bigotes (Box-Plot) son herramientas gráficas muy útiles para describir características importantes en un conjunto de datos, como son centro, simetría o asimetría, valores atípicos, etc.

La construcción de este diagrama emplea medidas descriptivas que son poco sensibles a datos extremos y por lo tanto presentan una descripción más clara de la información.

Valores atípicos (outliers)

Los valores atípicos en un conjunto de datos son aquellos que son mucho mayores o mucho menores que el resto de los valores.

Pero, ¿cuánto mayor o menor?. Utilizaremos el siguiente criterio:

- Una observación es **atípica o inusual** si está a más de 1.5 veces el rango intercuartil de alguno de los cuartiles Q_1 o Q_3 .
- Una observación es **atípica extrema** si está a más de 3 veces el rango intercuartil de alguno de los cuartiles Q_1 o Q_3 .


Por lo tanto, en general se dice que son valores atípicos todos aquellos que no pertenecen al intervalo:

$$[Q_1 - 1,5RI; Q_3 + 1,5RI]$$


Construcción

El diagrama está conformado por una caja la cual se construye con ayuda del primer y tercer cuartil. La mediana es dibujada en el interior de la caja al igual que la media muestral. Los bigotes se extienden desde los cuartiles a la derecha y a la izquierda. Su longitud depende de si hay o no datos atípicos.

Sin valores Atípicos ni Extremos:



Con valores Atípicos y/o Extremos:



Aclaración: este diagrama puede construirse de manera horizontal o vertical.

A partir de un boxplot se puede obtener con suma facilidad una serie de medidas descriptivas, mediante una inspección visual o cálculos muy simples, como el rango (diferencia entre ambos extremos de los bigotes), rango intercuartil, cuartiles, mediana.

También se puede observar la simetría: comparando la posición de la mediana con respecto a los cuartiles o comparando las respectivas longitudes de los bigotes.

Sin embargo, **una desventaja** del boxplot es que no contempla las distribuciones que no sean unimodales.

La principal **ventaja** que presenta es que puede utilizarse con fines comparativos de varias distribuciones o de varios subgrupos en una muestra.

Para ello se sitúan los diversos gráficos en paralelo y esto permite observar sus diferencias en localización y dispersión e incluso la simetría estudiando las longitudes de los bigotes.

Ejemplo:

Los siguientes datos corresponden a la cantidad de días entre la última helada de la primavera y la primera helada de otoño en una determinada zona agrícola considerando los últimos 30 años.

279 244 318 262 335 321 165 180 201 252 145 192 217 179 182
210 271 302 169 192 156 181 156 125 166 248 198 220 134 189

En primer lugar, debemos ordenar los datos de menor a mayor:

125 134 145 156 156 165 166 169 179 180 181 182 192 192 198
201 210 217 220 244 248 252 262 271 279 282 302 318 321 335

$$\text{Min}=125 \quad \text{Max}=335 \quad \text{Me} = 199,5 \quad Q_1 = 169 \quad Q_3 = 262 \quad \text{RI} = 93$$

Calculamos ahora los límites para ver si se encuentran valores atípicos.

$$Q_1 - 1,5 \times \text{RI} = 169 - 1,5 \times 93 = 29,5$$


$$Q_3 + 1,5 \times \text{RI} = 262 + 1,5 \times 93 = 401,5$$

No se detectan valores atípicos.

(Todos los valores de la variable pertenecen al intervalo: [29.5;401.5])

Gráfico N 6

Cantidad de días entre la última helada de la primavera y la primera helada de otoño en una determinada zona agrícola en los últimos 30 años



Observación: el bigote de arriba del boxplot es mas largo que el de abajo lo cual evidencia una menor concentración de datos en la parte izquierda de la distribución.

Ejemplo:

En un experimento se probó la eficacia de cierto insecticida. Para ello se consideraron 50 parcelas de un cultivo atacado por un insecto en particular. Al cabo de un cierto tiempo de aplicación del insecticida, se contó el número de insectos vivos por parcela.

6 5 7 5 5 6 6 9 6 6 5 6 6 6 7 7 8 7 7 7 7 10 7 5 8 9 8 7 8 8 8 11 8
8 8 8 9 6 9 9 8 9 9 10 7 10 10 8 11 14

Ordenamos los datos de menor a mayor:

5 5 5 5 5 6 6 6 6 6 6 6 6 6 6 7 7 7 7 7 7 7 7 7 7 8 8 8 8 8 8 8 8 8 8
8 8 9 9 9 9 9 9 9 10 10 10 10 10 11 11 14

$$\text{Min}=5 \quad \text{Max}=14 \quad \text{Me} = 8 \quad Q_1 = 6 \quad Q_3 = 9 \quad \text{RI} = 3$$

Calculamos ahora los límites para ver si se encuentran valores atípicos.

$$Q_1 - 1,5 \times \text{RI} = 6 - 1,5 \times 3 = 1,5$$

$$Q_3 + 1,5 \times \text{RI} = 9 + 1,5 \times 3 = 13,5$$

Se detecta un valor atípico: 14 ($14 \notin [1,5; 13,5]$)

Calculamos ahora los límites para ver si se encuentran valores atípicos extremos.


$$Q_1 - 3 \times \text{RI} = 6 - 3 \times 3 = -3$$

$$Q_3 + 3 \times \text{RI} = 9 + 3 \times 3 = 18$$

No se detectan un valores atípicos extremos.


Gráfico N 7

Cantidad de insectos vivos por parcela de un determinado cultivo



Análisis de Caso

3. En la siguiente figura se muestra la cantidad de huevos por nido en tres especies de aves acuáticas: Garza, Flamenco y Cisne.



- a) ¿Cuál de las especies presenta mayor dispersión en el número de huevos? Justifique su respuesta. **(4p)**
- b) ¿Qué especie presenta datos atípicos? ¿Cómo se identifican en el gráfico? **(4p)**
- c) ¿Alguna distribución parece simétrica? Fundamente observando el gráfico. **(4p)**
- d) ¿Qué medidas descriptivas se pueden observar en un boxplot? Menciónelas e interprételas para una de las especies. **(10p)**